



الكلية التطبيقية

الجامعة السعودية الإلكترونية

SAUDI ELECTRONIC UNIVERSITY

2011-1432

دبلوم الذكاء الاصطناعي التوليدي

اسم المقرر: الإحصاء و تحليل البيانات لعلوم الآلة
رمز المقرر: STA104
الموضوع: مقدمة إلى تعلم الآلة



الموضوع الحادي عشر: مقدمة إلى تعلم الآلة



الأهداف

في نهاية هذا الدرس ستكون قادرًا على أن:

- ✓ فهم المفهوم الأساسي لتعلم الآلة وتمييزه عن البرمجة التقليدية
- ✓ التعرف على أنواع تعلم الآلة الرئيسية (الخاضع للإشراف، غير الخاضع للإشراف، التعزيزي)
- ✓ فهم الفرق بين التصنيف والانحدار في التعلم الخاضع للإشراف
- ✓ إدراك مفاهيم البيانات التدريبية والاختبارية وأهمية كل منهما فهم مشكلة الإفراط في التعلم (Overfitting) والتعلم الناقص (Underfitting)
- ✓ التعرف على خطوات بناء نموذج تعلم الآلة
- ✓ فهم معايير تقييم نماذج تعلم الآلة
- ✓ التعرف على أشهر خوارزميات تعلم الآلة وتطبيقاتها العملية
- ✓ إدراك العلاقة بين تعلم الآلة والذكاء الاصطناعي والتعلم العميق
- ✓ فهم التحديات الأخلاقية والعملية في تطبيق تعلم الآلة



وصف الدرس

يمثل تعلم الآلة أحد أهم مجالات علم الحاسوب والذكاء الاصطناعي في العصر الحديث، حيث يمكن الحواسيب من التعلم واتخاذ القرارات من البيانات دون برمجة صريحة لكل حالة. في هذا الدرس، سنستكشف المبادئ الأساسية لتعلم الآلة بطريقة شاملة ومنهجية، بدءاً من فهم الفلسفة الكامنة وراء جعل الآلات تتعلم، مروراً بالأنواع المختلفة لخوارزميات التعلم وكيفية عملها، وصولاً إلى فهم كيفية بناء وتقييم نماذج فعالة. سنتناول بالتفصيل الفرق بين التعلم الخاضع للإشراف الذي يعتمد على البيانات الموسومة، والتعلم غير الخاضع للإشراف الذي يكتشف الأنماط الخفية في البيانات، بالإضافة إلى التعلم التعزيزي الذي يتعلم من خلال التفاعل مع البيئة. سنناقش أيضاً التحديات الرئيسية التي تواجه ممارسي تعلم الآلة مثل الإفراط في التعلم وقلة البيانات والتحيز، وكيفية التعامل معها. يهدف هذا الدرس إلى بناء أساس نظري متين يمكن الطالب من فهم المنطق وراء تطبيقات تعلم الآلة المختلفة التي نراها في حياتنا اليومية، من التوصيات في منصات التجارة الإلكترونية إلى التعرف على الوجوه في الهواتف الذكية، ومن التشخيص الطبي إلى القيادة الذاتية للمركبات.



عنوان | ما هو تعلم الآلة؟

التعريف الأساسي:

تعلم الآلة هو فرع من الذكاء الاصطناعي يمكّن أنظمة الحاسوب من التعلم والتحسين تلقائياً من الخبرة دون أن تتم برمجتها بشكل صريح لكل حالة محددة. بعبارة أخرى، تعلم الآلة يعطي الحواسيب القدرة على التعلم من البيانات واكتشاف الأنماط واتخاذ القرارات بأقل تدخل بشري ممكن.

التعريف الكلاسيكي لآرثر سامويل (1959):

"تعلم الآلة هو مجال الدراسة الذي يعطي الحواسيب القدرة على التعلم دون أن تتم برمجتها بشكل صريح."

التعريف الحديث لتوم ميتشل (1998):

"يقال إن برنامج الحاسوب يتعلم من الخبرة E فيما يتعلق بمجموعة من المهام T ومقياس الأداء P ، إذا تحسن أداؤه في المهام T كما يقاس بـ P مع الخبرة E ."

الفكرة الجوهرية:

بدلاً من كتابة قواعد محددة لحل مشكلة ما، نعطي الحاسوب أمثلة (بيانات) ونتركه يستنتج القواعد بنفسه.

عنوان | البرمجة التقليدية مقابل تعلم الآلة

البرمجة التقليدية: Traditional Programming

- المدخلات: البيانات + القواعد المبرمجة
- المخرجات: النتائج
- المثال: برنامج لفرز الأرقام من الأصغر للأكبر - نكتب الخوارزمية خطوة بخطوة
- التحدي: يصعب كتابة قواعد لمشاكل معقدة (مثل التعرف على الوجوه)

تعلم الآلة: Machine Learning

- المدخلات: البيانات + النتائج المطلوبة
- المخرجات: القواعد (النموذج)
- المثال: نعطي النظام آلاف الصور مع التسميات (هذا وجه، هذا ليس وجه)، فيتعلم القواعد بنفسه
- الميزة: يمكن حل مشاكل معقدة جداً لا نستطيع برمجتها يدوياً
- الاختلاف الجوهرى:

في البرمجة التقليدية نحن نعلم الحاسوب "كيف" يفعل الشيء، بينما في تعلم الآلة نعلمه "ماذا" نريد ونتركه يكتشف "كيف" بنفسه.

عنوان | تعلم الآلة والذكاء الاصطناعي والتعلم العميق

العلاقة بين المفاهيم:

الذكاء الاصطناعي: AI - Artificial Intelligence

- المجال الأوسع - أي نظام يحاكي الذكاء البشري
- يشمل: الروبوتات، معالجة اللغة الطبيعية، الرؤية الحاسوبية، وغيرها

تعلم الآلة ML - Machine Learning

- مجموعة فرعية من الذكاء الاصطناعي
- يركز على الأنظمة التي تتعلم من البيانات
- يشمل: الخوارزميات التي تحسن أداؤها تلقائياً

التعلم العميق DL - Deep Learning

- مجموعة فرعية من تعلم الآلة
- يستخدم الشبكات العصبية العميقة (متعددة الطبقات)
- فعال جداً في المشاكل المعقدة مثل التعرف على الصور والكلام

التسلسل الهرمي:

الذكاء الاصطناعي < تعلم الآلة < التعلم العميق

عنوان | لماذا تعلم الآلة مهم؟

الأسباب الرئيسية:

1. حجم البيانات الهائل:

نعيش في عصر البيانات الضخمة، حيث نوّلد كميات هائلة من البيانات يومياً. تعلم الآلة يمكنه استخراج معلومات قيمة من هذه البيانات بطرق يستحيل على البشر القيام بها يدوياً.

2. المشاكل المعقدة:

بعض المشاكل معقدة جداً بحيث لا يمكن حلها بالبرمجة التقليدية، مثل التعرف على الكلام بلهجات مختلفة، أو تشخيص الأمراض من الأشعة الطبية.

3. الأتمتة والكفاءة:

تعلم الآلة يمكّننا من أتمتة مهام كانت تتطلب تدخلاً بشرياً، مما يوفر الوقت والجهد ويقلل الأخطاء.

4. التخصيص:

يمكّن الشركات من تقديم تجارب مخصصة لكل مستخدم (مثل توصيات Netflix أو Amazon).

5. اتخاذ قرارات أفضل:

يساعد في تحليل البيانات واكتشاف أنماط غير ظاهرة للعين البشرية، مما يدعم اتخاذ قرارات مبنية على بيانات حقيقية.

عنوان | أنواع تعلم الآلة - نظرة عامة

تصنف خوارزميات تعلم الآلة إلى ثلاثة أنواع رئيسية:

1. التعلم الخاضع للإشراف: Supervised Learning

- نعطي النموذج بيانات موسومة (مُصنفة مسبقاً)

- الهدف: التنبؤ بالتسميات للبيانات الجديدة

- مثل: معلم يشرف على تعلم الطالب بإعطائه الأسئلة والأجوبة الصحيحة

2. التعلم غير الخاضع للإشراف: Unsupervised Learning

- نعطي النموذج بيانات غير موسومة

- الهدف: اكتشاف الأنماط والبنى الخفية في البيانات

- مثل: طالب يستكشف موضوعاً بمفرده دون معلم

3. التعلم التعزيزي: Reinforcement Learning

- النموذج يتعلم من خلال التفاعل مع البيئة

- الهدف: تعظيم المكافأة على المدى الطويل

- مثل: تدريب حيوان أليف بالمكافآت والعقوبات

عنوان | التعلم الخاضع للإشراف Supervised Learning

المفهوم الأساسي:

في التعلم الخاضع للإشراف، نقدم للنموذج مجموعة من الأمثلة التدريبية، حيث كل مثال يتكون من مدخلات (features) ومخرجات معروفة (labels). النموذج يتعلم العلاقة بين المدخلات والمخرجات، ثم يستخدم هذه المعرفة للتنبؤ بمخرجات بيانات جديدة لم يرها من قبل.

المكونات الأساسية:

- البيانات التدريبية: أمثلة موسومة نستخدمها لتدريب النموذج
- الميزات (Features): المتغيرات المستقلة (المدخلات)
- التسميات (Labels): المتغير التابع (المخرج المطلوب التنبؤ به)

مثال توضيحي:

لنفترض أننا نريد بناء نموذج للتنبؤ بأسعار المنازل. نعطي النموذج بيانات تاريخية عن منازل تم بيعها، تحتوي على:

• الميزات: المساحة، عدد الغرف، الموقع، العمر

• التسمية: السعر الفعلي للمنزل

النموذج يتعلم العلاقة بين هذه الميزات والسعر، ثم يستطيع التنبؤ بسعر منزل جديد.

عنوان | أنواع مهام التعلم الخاضع للإشراف

ينقسم التعلم الخاضع للإشراف إلى نوعين رئيسيين:

1. الانحدار: Regression

- الهدف: التنبؤ بقيمة عددية مستمرة
- المخرج: رقم حقيقي (يمكن أن يأخذ أي قيمة في نطاق معين)
- أمثلة:

- التنبؤ بأسعار المنازل (100,000 ريال، 250,000 ريال، إلخ)
- التنبؤ بدرجة الحرارة غداً (25.5°C, 30.2°C, إلخ)
- التنبؤ بمبيعات المتجر الشهر القادم (15,000 ريال، 20,500 ريال، إلخ)

2. التصنيف: Classification

- الهدف: التنبؤ بفئة أو تصنيف منفصل
- المخرج: فئة من مجموعة محدودة من الفئات
- أمثلة:
- تصنيف ثنائي: البريد الإلكتروني (spam أو not spam)، المريض (مصاب أو غير مصاب)
- تصنيف متعدد الفئات: نوع الحيوان (قط، كلب، طائر)، نوع الزهرة (ورد، ياسمين، زنبق)
- الفرق الجوهرى:

الانحدار يتعامل مع أرقام مستمرة، بينما التصنيف يتعامل مع فئات منفصلة.

عنوان | التعلم غير الخاضع للإشراف Unsupervised Learning

المفهوم الأساسي:

في التعلم غير الخاضع للإشراف، نعطي النموذج بيانات غير موسومة، أي لا نخبره بالإجابات الصحيحة. الهدف هو اكتشاف البنية الكامنة أو الأنماط الخفية في البيانات دون توجيه مسبق.
الأنواع الرئيسية:

1. التجميع: Clustering

• تقسيم البيانات إلى مجموعات clusters بناءً على التشابه
• أمثلة:

- تجميع العملاء إلى فئات متشابهة لأغراض التسويق
- تجميع المقالات الإخبارية حسب الموضوع
- تجميع الجينات ذات الأنماط المتشابهة في الأبحاث الطبية

2. تقليل الأبعاد: Dimensionality Reduction

• تقليل عدد المتغيرات مع الحفاظ على المعلومات المهمة
• أمثلة:

- ضغط الصور مع الحفاظ على الجودة
- تبسيط البيانات المعقدة للتصور البياني

3. اكتشاف الارتباطات: Association Rule Learning

• اكتشاف العلاقات المثيرة للاهتمام بين المتغيرات
• مثال: تحليل سلة المشتريات - "العملاء الذين اشترؤا الخبز غالباً يشترون الحليب"

عنوان | التعلم التعزيزي Reinforcement Learning

المفهوم الأساسي:

التعلم التعزيزي هو نوع من تعلم الآلة يتعلم فيه النموذج (يُسمى العامل أو Agent) كيفية اتخاذ القرارات من خلال التفاعل مع بيئة ما. العامل يتخذ إجراءات، ويحصل على مكافآت أو عقوبات بناءً على هذه الإجراءات، ويتعلم من خلال التجربة والخطأ لتعظيم المكافأة التراكمية على المدى الطويل. المكونات الأساسية:

- العامل: Agent النموذج الذي يتخذ القرارات
 - البيئة: Environment العالم الذي يتفاعل معه العامل
 - الحالة: State الوضع الحالي للبيئة
 - الإجراء: Action القرار الذي يتخذه العامل
 - المكافأة: Reward التغذية الراجعة التي يحصل عليها العامل
- أمثلة تطبيقية:
- الألعاب: برنامج AlphaGo الذي تفوق على بطل العالم في لعبة Go
 - الروبوتات: تعليم الروبوت المشي أو الإمساك بالأشياء
 - القيادة الذاتية: تعليم السيارة القيادة الآمنة
 - التداول المالي: بناء أنظمة تتخذ قرارات الاستثمار
- الفكرة الأساسية:
- العامل يتعلم من خلال التجربة - يحاول، يخطئ، يتعلم، ويحسن أدائه تدريجياً.

عنوان | البيانات في تعلم الآلة

أهمية البيانات:

البيانات هي الوقود الذي يشغل نماذج تعلم الآلة. بدون بيانات جيدة ومناسبة، لا يمكن بناء نموذج فعال، مهما كانت الخوارزمية متطورة. هناك مقولة شهيرة في المجال: "Garbage In, Garbage Out" - إذا أدخلت بيانات سيئة، ستحصل على نتائج سيئة.

أنواع البيانات:

1. البيانات التدريبية: Training Data

- تستخدم لتدريب النموذج وتعليمه الأنماط
- عادة ما تشكل 70-80% من إجمالي البيانات

2. بيانات التحقق: Validation Data:

- تستخدم لضبط معاملات النموذج واختيار أفضل نموذج
- عادة ما تشكل 10-15% من البيانات

3. بيانات الاختبار: Test Data:

- تستخدم لتقييم الأداء النهائي للنموذج على بيانات لم يرها من قبل
- عادة ما تشكل 10-15% من البيانات

- **مهم جداً:** يجب ألا يرى النموذج هذه البيانات أثناء التدريب أبداً

مبدأ أساسي:

فصل البيانات ضروري لتقييم قدرة النموذج على التعميم على بيانات جديدة، وليس فقط حفظ البيانات التدريبية.

عنوان | الميزات والهندسة Features and Feature Engineering

ما هي الميزات Features؟

الميزات هي الخصائص أو السمات القابلة للقياس في البيانات التي نستخدمها لتدريب النموذج. اختيار الميزات المناسبة هو أحد أهم عوامل نجاح نموذج تعلم الآلة.

أمثلة على الميزات:

- في التنبؤ بأسعار المنازل: المساحة، الموقع، عدد الغرف، العمر
- في التعرف على الصور: الألوان، الحواف، الأشكال، الأنسجة
- في التصنيف الطبي: العمر، الوزن، الطول، الأعراض، نتائج الفحوصات

هندسة الميزات Feature Engineering:

هي عملية استخدام المعرفة المجالية لإنشاء ميزات جديدة من البيانات الخام تجعل خوارزميات تعلم الآلة تعمل بشكل أفضل.

أمثلة على هندسة الميزات:

- الدمج: من تاريخ الميلاد، نستخرج العمر
- التحويل: من المساحة والسعر، نحسب السعر لكل متر مربع
- التفاعل: ضرب ميزتين معاً (مثل المساحة × عدد الغرف)
- التصنيف: تحويل الأعمار إلى فئات (طفل، شاب، كبير السن)

قاعدة ذهبية:

ميزات جيدة + خوارزمية بسيطة < ميزات سيئة + خوارزمية معقدة

عنوان | عملية بناء نموذج تعلم الآلة

الخطوات الأساسية:

1. تحديد المشكلة:

- ما المشكلة التي نريد حلها؟
- هل هي مشكلة تصنيف أم انحدار أم تجميع؟
- ما هو الهدف المحدد الذي نريد تحقيقه؟

2. جمع البيانات:

- جمع بيانات كافية وممثلة للمشكلة
- التأكد من جودة البيانات ومصادقتها

3. استكشاف البيانات وتنظيفها:

- فحص البيانات وفهم خصائصها
- التعامل مع القيم المفقودة والشاذة
- إزالة التكرارات والبيانات غير الصحيحة

4. هندسة الميزات:

- اختيار الميزات المهمة
- إنشاء ميزات جديدة مفيدة
- تحويل البيانات إلى الصيغة المناسبة

5. اختيار الخوارزمية:

- اختيار الخوارزمية المناسبة للمشكلة
- قد نجرب عدة خوارزميات مختلفة

6. تدريب النموذج:

- تدريب النموذج على البيانات التدريبية
- ضبط معاملات النموذج ((Hyperparameters

7. تقييم النموذج:

- اختبار النموذج على بيانات لم يرها من قبل
- قياس الأداء باستخدام معايير مناسبة

8. النشر والمراقبة:

- نشر النموذج في بيئة الإنتاج
- مراقبة أدائه وتحديثه عند الحاجة

عنوان | الإفراط في التعلم والتعلم الناقص

مشكلتان أساسيتان في تعلم الآلة:

1. الإفراط في التعلم: Overfitting

- التعريف: النموذج يحفظ البيانات التدريبية بدلاً من تعلم الأنماط العامة
- الأعراض: أداء ممتاز على البيانات التدريبية، لكن أداء سيئ على البيانات الجديدة
- السبب: نموذج معقد جداً بالنسبة لكمية البيانات المتاحة
- التشبيه: طالب يحفظ الإجابات حرفياً بدلاً من فهم المفاهيم، فينجح في نفس الأسئلة لكن يفشل في أسئلة مشابهة
- الحلول:

- جمع المزيد من البيانات التدريبية
- تبسيط النموذج (تقليل التعقيد)
- استخدام تقنيات التنظيم ((Regularization
- استخدام التحقق المتقاطع ((Cross-validation

2. التعلم الناقص: (Underfitting)

- التعريف: النموذج بسيط جداً ولا يستطيع التقاط الأنماط في البيانات
- الأعراض: أداء سيئ على كل من البيانات التدريبية والاختبارية
- السبب: نموذج بسيط جداً أو ميزات غير كافية
- التشبيه: محاولة رسم منحنى معقد بخط مستقيم
- الحلول:

- استخدام نموذج أكثر تعقيداً
- إضافة المزيد من الميزات
- تقليل التنظيم إذا كان مفرطاً

الهدف المثالي:

نموذج متوازن يتعلم الأنماط العامة دون حفظ التفاصيل الدقيقة.

عنوان | أشهر خوارزميات التعلم الخاضع للإشراف

خوارزميات التصنيف والانحدار:

1. الانحدار الخطي (Linear Regression):

- للانحدار (التنبؤ بقيم مستمرة)

- بسيطة وسريعة وسهلة التفسير

- مناسبة عندما تكون العلاقة خطية

2. الانحدار اللوجستي (Logistic Regression):

- للتصنيف الثنائي (رغم الاسم)

- تحسب احتمالية انتماء المثال لفئة معينة

- سريعة وفعالة

3. أشجار القرار (Decision Trees):

- للتصنيف والانحدار

- سهلة الفهم والتفسير

- يمكن أن تعاني من الإفراط في التعلم

4. الغابات العشوائية (Random Forests):

- مجموعة من أشجار القرار

- أكثر دقة من شجرة واحدة

- أقل عرضة للإفراط في التعلم

5. آلات المتجهات الداعمة (Support Vector Machines - SVM):

- فعالة جداً في التصنيف

- تعمل جيداً مع البيانات عالية الأبعاد

- قد تكون بطيئة مع البيانات الكبيرة

6. K-أقرب الجيران (K-Nearest Neighbors - KNN):

- للتصنيف والانحدار

- بسيطة جداً: تصنف بناءً على أقرب الجيران

- بطيئة في التنبؤ مع البيانات الكبيرة

7. الشبكات العصبية (Neural Networks):

- مرنة جداً وقوية

- تحتاج بيانات كثيرة

- أساس التعلم العميق

عنوان | أشهر خوارزميات التعلم غير الخاضع للإشراف

خوارزميات التجميع:

1. K-Means:

- تقسم البيانات إلى K مجموعة
- بسيطة وسريعة
- تحتاج لتحديد عدد المجموعات مسبقاً

2. التجميع الهرمي (Hierarchical Clustering):

- تبني هرمية من المجموعات
- لا تحتاج لتحديد عدد المجموعات مسبقاً
- يمكن تصور النتائج في شكل شجري (Dendrogram)

3. DBSCAN:

- تجميع قائم على الكثافة
- يمكنه اكتشاف أشكال غير منتظمة
- يتعامل جيداً مع القيم الشاذة

خوارزميات تقليل الأبعاد:

1. PCA (Principal Component Analysis):

- تحلل المكونات الأساسية
- تقلل الأبعاد مع الحفاظ على أكبر قدر من التباين
- مفيدة للتصور وتسريع التدريب

2. t-SNE:

- ممتازة لتصور البيانات عالية الأبعاد في 2 أو 3D
- تحافظ على البنية المحلية للبيانات
- بطيئة نسبياً

خوارزميات اكتشاف الشذوذ:

1. Isolation Forest:

- تكتشف القيم الشاذة عن طريق عزلها
- فعالة مع البيانات الكبيرة

2. One-Class SVM:

- تتعلم ما هو "طبيعي" وتكتشف الشذوذ

عنوان | تطبيقات تعلم الآلة في الحياة اليومية

تطبيقات نراها ونستخدمها يومياً:

1. التعرف على الصور والوجوه:

• فتح الهاتف بالوجه ((Face ID

• وسم الأصدقاء في الصور على فيسبوك

• البحث عن الصور في Google Photos

2. معالجة اللغة الطبيعية:

• المساعدات الصوتية ((Siri, Alexa, Google Assistant

• الترجمة الآلية ((Google Translate

• تصحيح الإملاء والنحو

3. أنظمة التوصية:

• توصيات الأفلام في Netflix

• توصيات المنتجات في Amazon

• توصيات الأغاني في Spotify

• توصيات الفيديوهات في YouTube

4. التجارة الإلكترونية:

• التنبؤ بالطلب وإدارة المخزون

• تحسين الأسعار الديناميكية

• كشف الاحتيال في المعاملات

5. الرعاية الصحية:

• تشخيص الأمراض من الصور الطبية

• التنبؤ بتفشي الأوبئة

• اكتشاف الأدوية الجديدة

• الطب الشخصي

6. النقل:

• السيارات ذاتية القيادة

• تحسين المسارات في تطبيقات الخرائط

• التنبؤ بالازدحام المروري

7. الأمن السيبراني:

• كشف البريد المزعج ((Spam Detection

• كشف البرمجيات الخبيثة

• كشف الاختراقات الأمنية

8. المالية:

• التداول الخوارزمي

• تقييم المخاطر الائتمانية

• كشف الاحتيال في البطاقات

عنوان | التحديات والاعتبارات الأخلاقية

الاعتبارات الأخلاقية:

1. التحيز (Bias):

- النماذج قد ترث التحيزات الموجودة في البيانات التدريبية
- مثال: نظام توظيف يميز ضد جنس معين لأن البيانات التاريخية متحيزة
- الحل: فحص البيانات والنماذج بعناية لضمان العدالة

2. الخصوصية:

- استخدام البيانات الشخصية يثير قضايا الخصوصية
- الحاجة لحماية معلومات المستخدمين
- الامتثال للقوانين مثل GDPR

3. الشفافية:

- حق المستخدمين في معرفة كيف تُتخذ القرارات التي تؤثر عليهم
- أهمية شرح النماذج والقرارات

4. المساءلة:

- من المسؤول عندما يخطئ نموذج تعلم الآلة؟
- أهمية وضع آليات للمساءلة

5. التأثير على الوظائف:

- الأتمتة قد تؤدي لفقدان بعض الوظائف
- الحاجة لإعادة التأهيل والتدريب

6. الأمان:

- النماذج قد تكون عرضة للهجمات (Adversarial Attacks)
- أهمية تأمين الأنظمة ضد الاستغلال

التحديات التقنية:

1. جودة البيانات:

- البيانات المفقودة أو غير الكاملة
- البيانات المتحيزة أو غير الممثلة
- حجم البيانات غير الكافي

2. قابلية التفسير:

- بعض النماذج (مثل الشبكات العصبية العميقة) تعمل كـ "صندوق أسود"
- صعوبة شرح كيفية اتخاذ القرارات
- مهم في المجالات الحساسة مثل الطب والقانون

3. الموارد الحسابية:

- تدريب النماذج المعقدة يتطلب قوة حسابية كبيرة
- التكلفة المرتفعة للأجهزة والكهرباء

Practical Statistics for Data Scientists – Peter Bruce

لکم شکراً

